

Projeto Final do Semestre

Construindo um Assistente de IA Local

4 fases · Do Chat Simples ao Assistente Multimodal



VISÃO GERAL DO PROJETO

O que vamos construir?



Fase 1

Chat Local

Phi-3 rodando no notebook com interface HTML/CSS/JS



Fase 2

Chat com PDF

Upload de PDF e conversa sobre o conteúdo



Fase 3

Chat com Áudio

Upload de .mp3/.mp4 e conversa sobre o que foi falado



Fase 4

Chat com Vídeo

Upload de vídeo e chat sobre o conteúdo falado

Cada fase é entregue como incremento — vocês partem do projeto anterior e evoluem!

</> FASE 1 — Chat Local com Phi-3

Objetivo

Baixar e rodar o modelo Phi-3 (da Microsoft) localmente usando o Ollama, e criar uma interface de chat simples no browser — sem custo, sem API paga.

Entregas

-  Núcleo do chatbot com LLM rodando
-  Ollama instalado e Phi-3 configurado
-  Interface HTML com campo de pergunta e resposta
-  CSS básico (responsivo e legível)
-  JavaScript com fetch para API local do Ollama
-  Histórico de conversa na tela

Ferramentas (gratuitas!)

Ollama

Roda LLMs localmente — grátis e open-source

Phi-3 Mini

Modelo da Microsoft, leve (~2.3 GB), roda em CPU

HTML + CSS

Interface simples, sem framework

JavaScript puro

fetch() para chamar a API REST do Ollama

VS Code

Editor de código recomendado (grátis)



FASE 2 — Chat com PDF

Objetivo

Adicionar ao projeto da Fase 1 a capacidade de ler PDFs. O usuário faz upload de um arquivo, o texto é extraído pelo browser e enviado ao modelo como contexto.

Entregas

-  Usuário faz upload do PDF
-  PDF.js extrai o texto
-  Texto bruto é gerado
-  UI mostra que PDF foi carregado
-  Texto entra no prompt como contexto
-  Usuário faz perguntas sobre o conteúdo

Como funciona?

- 1 Usuário seleciona um .pdf no browser
- 2 PDF.js extrai o texto em JavaScript, sem servidor
- 3 Texto vai no prompt: "Contexto: [texto]\nPergunta: ..."
- 4 Phi-3 responde com base no conteúdo do PDF
- 5 Chat continua normalmente no histórico

 PDFs muito longos: extrair somente as primeiras N páginas



FASE 3 — Chat com Áudio

Objetivo

Adicionar suporte a arquivos de áudio (.mp3 ou .mp4). O áudio é transcrito localmente com o Whisper e o texto resultante vira o contexto do chat.

Entregas

-  Upload do áudio (.mp3 / .mp4)
-  Transcrição (Whisper)
-  Áudio é convertido em texto
-  Texto entra no prompt junto com a pergunta
-  Usuário faz perguntas sobre o conteúdo

Opções de Transcrição

Whisper.cpp (recomendado)

Binário C++, sem Python, roda em CPU, bem rápido para áudios curtos

openai-whisper (Python)

`pip install openai-whisper` — modelo small é suficiente e leve

whisper.js (browser, experim.)

Roda direto no browser via WebAssembly — sem servidor backend



Usar modelo 'small' do Whisper (~150 MB) para economizar espaço



FASE 4 — Chat com Vídeo

Objetivo

Estender o projeto para aceitar vídeos (.mp4). O áudio do vídeo é extraído, transcrito com Whisper e usado como contexto — mesma lógica da Fase 3!

Entregas

-  Upload de arquivos .mp4 na interface
-  Extração do áudio com FFmpeg (gratuito)
-  Transcrição com Whisper (reutilizando etapa anterior)
-  Texto entra no prompt junto com a pergunta
-  Chat sobre o conteúdo do vídeo

Pipeline Técnico



Upload .mp4

Usuário sobe o vídeo



FFmpeg extrai áudio

`ffmpeg -i video.mp4 audio.mp3`



Whisper transcreve

Texto em linguagem natural



Phi-3 responde

Contexto + pergunta do usuário



FFmpeg é free/open-source — disponível para Windows, Mac e Linux



REQUISITOS & AVALIAÇÃO

Forma de Entrega

-  Repositório GitHub (público ou privado com acesso)
-  README explicando como rodar o projeto
-  Vídeo curto (~3 min) demonstrando cada fase
-  Entrega incremental — uma fase por vez
-  Individual ou  dupla (a combinar)

Requisitos Mínimos

-  Notebook com **8 GB de RAM** ou mais
-  SO: **Windows 10/11, macOS ou Linux**
-  Conexão com a internet para baixar os modelos (1x)

Pontuação por Fase

Fase 1 — Chat HTML/JS **25 pts**

Fase 2 — Chat com PDF **25 pts**

Fase 3 — Chat com Áudio **25 pts**

Fase 4 — Chat com Vídeo **25 pts**

TOTAL **100 pts**



DICAS & RECURSOS GRATUITOS

ollama.com



Download do Ollama — roda Phi-3, LLaMA, Mistral no notebook

ffmpeg.org



Extração de áudio de vídeos (.mp4 → .mp3) — linha de comando simples

mozilla.github.io/pdf.js



Biblioteca JS para ler PDFs no browser (sem backend)

docs.ollama.com/api



Documentação da API REST local — fácil de chamar com fetch()

github.com/ggerganov/whisper.cpp



Whisper em C++ — transcrição local, rápida, sem GPU

code.visualstudio.com



VS Code — editor gratuito recomendado para o projeto


Bora construir!

Este projeto vai sair do computador de vocês.

Não precisa de GPU.

Não precisa pagar API.

Só precisa de curiosidade e vontade de aprender.



Dúvidas? Compartilhem no grupo da turma. Bom projeto a todos! 🚀